8 장 직접 화일

직접 화일의 개념

임의 접근 화일 = 직접 화일 = 직접 접근 화일

- 다른 레코드의 참조 없이도 개개 레코드를 접근 할 수 있는 것
- 레코드의 키 값을 통해 접근할 수 있는 파일

임의 접근 파일의 종류

- Indexed File

  인덱스를 이용하여 레코드에 접근한다.

- Indexed Sequential File

  인덱스를 이용한 임의 접근과 순차 접근을 모두 지원한다.

- Realtive File

  레코드 키와 주소 사이의 설정된 관계를 이용한다.

- Hash File

  키 값을 통해 레코드 주소를 생성한다. (상태 파일의 한 형태)

  협의의 직접 화일 (?)

상대파일 (Relative File)

레코드의 키와 레코드의 위치(상대 레코드 번호) 사이에 설정된 관계를 통해 레코드에 접근한다.

상대 파일을 정립 한다 == 키 값과 물리적 주소 사이를 서로 변환할 수 있는 어떤 관계를 정의하는 것

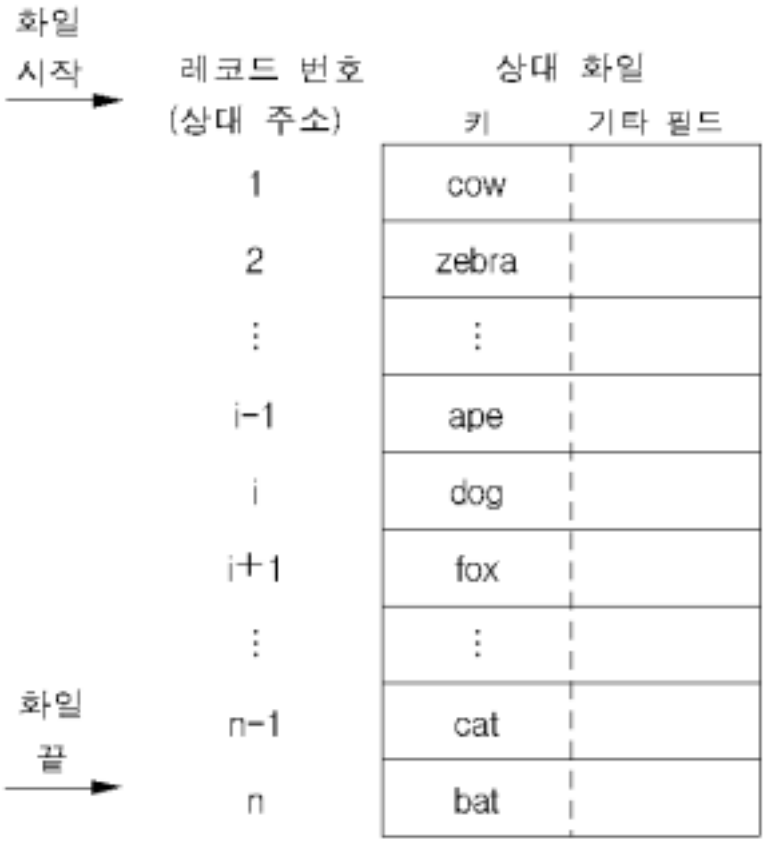

상대 레코드 번호 (Relative Record Number)

화일이 시작되는 첫번째 레코드를 0 번으로 지정하고, 이것을 기준으로 다음 레코드에 0, 1, 2, 3, ..., N-1 를 지정해준다. (시작 지점과 **상대**적인 **레코드 번호**)

레코드의 논리적 순서와 물리적 순서는 무관

레코드들이 키 값에 따라 물리적으로 정렬되어 있을 필요가 없다.

i 번째 레코드의 상대 레코드 번호 = i - 1

Mapping Function ... 사상 함수

상대 파일을 정립 한다 == 키 값과 물리적 주소 사이를 서로 변환할 수 있는 어떤 관계를 정의하는 것

이러한 관계를 A 라고 하면 <u>A 는 키 값을 화일의 주소로 사상시키는 하나의 사상 함수</u>가 된다.

A : 키 값 -> 주소

레코드 삽입 시 : 키 값 = 레코드가 저장 될 주소

레코드 검색 시 : 키 값 = 레코드가 저장되어있는 주소

모든 레코드에 직접 접근이 가능하다.

- 메인 메모리, 디스크 등 직접 저장 장치에 저장하는 것이 효율적이다.

사상 함수의 구현 방법

- 직접 사상
- 디렉터리 검사
- 계산을 이용한 방법 … LIKE Hashing

직접 사상

키 값 자체가 레코드의 실제 주소로, 절대 주소를 이용한다.

레코드가 파일에 처음 저장될 때 레코드의 주소(실린더 번호 / 면 번호 / 섹터 번호 , = 절대 주소) 가 결정된다.

장점 : 간단, 처리 시간이 거의 걸리지 않는다.

단점 : 물리적 저장장치에 의존적이다 …. 잘 사용되지 않는 방식이다.

디렉터리 검사

<키 값, (상대) 주소> 쌍을 엔트리로 하는 테이블 유지

검색 절차

디렉터리에서 키 값을 검색한다

키 값에 대응되는 레코드 번호(상대주소) 구함

레코드에 접근한다

장점 : 빠른 검색

단점 : 삽입 비용이 크다. 화일과 디렉터리 재구성이 필요하다.

구현 예시

– <키 값, 레코드 번호> 쌍을 엔트리로 갖는 배열 – 디렉터리 엔트리는 키 값으로 정렬 – 순차 접근은 가능하나 의미는 없음

해싱 (hashing)

Hash Function 을 통해 **키 값을 주소로 변환**하고 키에서 **변환된 주소에 레코드를 저장**한다.

장점 : 레코드의 주소를 구해 직접 접근이 가능하다. (접근시간이 빠르다)

키 공간 >> 주소 공간 : 일반적으로 키로 표현 할 수 있는 크기가 실제 사용 하는 주소 공간보다 크기가 크다

주민등록번호로 예시

- 가능한 키 값의 수 1013 개 (키 공간 = 1013)
- 실제 필요한 주소 수 : 108 (=1 억) 개 이하
- 주민등록번호(키) 각각 마다 화일에 빈 레코드 주소를 할당한다면 막대한 공간이 낭비된다.
- 1 억개의 레코드 공간을 갖는 파일을 만드는것이 매우 효율적이다.

Hashing Function

키 공간을 주소 공간으로 Mapping 해준다.

H(Key) -> Address , Address 는 유효한 주소 공간이다.

키 값들을 한정된 주소 공간으로 <u>**균등하게**</u> 분산시켜야한다.

해싱을 이용한 화일 설계시 고려 사항

1. 버킷의 크기
   - 하나의 주소를 가진 저장 구역에 저장할 수 있는 레코드의 수
   - 통상적으로 한 번의 접근으로 버킷 내에 있는 모든 레코드들을 전송할 수 있는 크기로 결정한다
   - 저장 장치의 물리적 특성과 연관
   - 1,000 개 레코드를 갖는 파일

     버킷의 크기가 1 인 경우 주소 공간은 1,000 (버킷 1,000 개)을 갖는다

     버킷의 크기가 5 인 경우 주소 공간은 200 (버킷 200 개) 이다.
   - 버킷 = 파일에서 같은 주소에 포함될 수 있는 최대 레코드 수

     둘 이상의 레코드 저장 가능

     같은 버킷 안의 레코드들은 같은 버킷 주소를 가짐

     버킷 수 = 파일의 주소 공간
   - 충돌(Collision)

     서로 다른 레코드가 똑같은 버킷으로 해싱되는 것

     동거자(Synonyms) : 같은 주소로 해싱되어 충돌된 키 값들

     버킷이 만원일 때는 충돌이 문제가 된다 ... Overflow 발생
   - 버킷의 크기를 크게 하면 충돌을 해결 할 수 있지 않은가?

     오버 플로우는 덜 발생한다.

     하지만 **저장 공간의 효율 감소**하며, 버킷 내에서 레코드를 **탐색하는데 시간이 증가**한다.
2. 적재율 (적재 밀도)

- 총 저장 용량에 대한 실제로 저장되는 레코드 수의 대한 비율
- 적재율 = <저장된 레코드 수> / < 버킷의 총 용량 > = K / (c * N) < 1
- 적재율 = <화일에 저장된 레코드 수> / (<버킷의 크기> * <버킷 수>)₩
- 적재 밀도가 큰 경우 (동거자가 많이 생긴다는 뜻)

  삽입시 접근 수가 많아진다.

  검색시 접근 수가 많아진다.
- 적재 밀도가 작은 경우 (쓸대없이 방이 크다)

  공간 효율이 떨어진다.
- <u>**실험적으로, 적재 밀도가 70% 보다 클 때, 충돌이 잦으므로, 30% 정도의 예비 공간이 필요하다**</u>

3. 해싱 함수 : 키를 버킷 주소로 변환하는 함수
   - 레코드 키 값으로부터 주소(버킷 주소)를 생성하는 방법
   - 일종의 변환 함수
   - 해싱함수의 계산 시간 << 보조기억장치의 버킷 접근 시간
   - 모든 주소에 대해 균일한 분포를 가져야함 (골고루)
   - 주소 변환 과정
     1. 키가 숫자가 아닌 경우, 키를 정수 값으로 변환 (output : A)
     2. 변환된 정수(A)를 주소 공간의 자리 수 만큼 다른 정수로 변환 (output : B)
     3. 얻어진 정수 B 를 주소공간의 실제범위에 맞게 조정 (output : 주소 = B * 조정상수)
4. 오버플로 해결 방법
   - 버킷이 꽉 찬 경우 어떻게 해결 할 것인가

해싱 방법

제산 잔여 해싱

- 제수

  직접 주소공간의 크기를 결정
  - 주소공간 : 0 ~ (제수 - 1)
  - 제수 > 화일의 크기

  충돌 가능성이 가장 적은 것으로 선택한다.
  - <u>**버킷수보다 작으면서 가장 큰 소수**</u>
  - <u>버킷수와 가장 가까운 소수</u>
  - 20 보다 작은 소수를 인수로 갖지 않는 비소수를 사용한다.

- 성능

    적당한 성능을 위한 적재율 최대 허용치는 0.7 ~ 0.8

    n 개의 레코드를 갖고 있다면 1.25n 주소 공간을 할당한다.

- 작동 방식

    1. 주소 = 키 값 % 제수 -> 0 ~ (제수 - 1)
    2. 주소 범위에 맞도록 조정 (조정 상수 사용)

- 예시)

    주소 공간 = 4,000 / 0.8 = 5,000

    제수 : 5003 (20 이하의 수를 인자로 가장 가까운 소수)

중간 제곱(Mid-square) 해싱

- 작동 방식

    1. 키 값을 제곱한다
    2. 중간에서 n 개의 수를 취한다 : 주소공간은 10n
    3. 조정 상수를 사용하여 주소 범위에 맞도록 조정한다.

- 예시)

    레코드 4,000 개, 적재율 80%

    최소 104 이므로 최소 네 자리의주소 공간이 필요하다.

    키를 제곱한 수에서 4 자리 수를 취한다

    주소공간 조정후, 주소공간의 실제 범위로 매핑한다. (4000/0.8)*0.5

중첩(Folding) 해싱

- 작동 방식

    1. 키 값을 주소공간과 같은 자리수(n 자리수)를 가지는 몇 개의 부분으로 나눈다
    2. 접어서 합을 구한다. 이때 주소 공간은 10n 이다.
    3. 조정 상수를 사용하여 주소 범위에 맞도록 조정한다.

숫자 분석 방법

- 작동 방식

    키 값이 되는 숫자의 분포 이용

    키들의 모든 자릿수에 대한 빈도 테이블을 만들고, 어느 정도 **균등한 분포를 갖는 자릿수를 주소로 사용**한다.

    단, **키 값들을 미리 알고 있어야 한다**는 단점이 있다.

숫자 이동 변환

- 작동 방식

중앙을 중심으로 키를 양쪽으로 나눈다.

주소 길이(n 자리수)만큼 겹치도록 안쪽으로 각각 shift 한다.

주소 범위에 맞도록 조정한다

진수 변환

- 작동 방식
  1. 키 값의 진수를 다른 진수로 변환한다
  2. 초과하는 높은 자리 수를 절단한다
  3. 주소 범위에 맞도록 조정한다.
- 예시

  키 값 = 172,148, 주소 공간 = 7,000, 진수 : 11

  변환된 값 : 266373(11)

  뒤에 4 자리 * 0.7 = 4461

충돌과 오버플로

Overflow 해결 방법

개방 주소법 : Overflow 된 동거자를 저장할 공간을 **상대 파일 내에서 찾아 해결**.

체인법 : 오버플로된 동거자를 위한 저장 공간을 **상대 파일 밖에서 찾아 해결**. (독립된 오버플로우 구역 할당)

해결 기법

선형 조사

```
insertLinear(key);
   addr ← h(key); // 변환된 주소
   home-addr ← addr; // 홈 주소
   while (addr is full) do { // 꽉 찬 경우 반복
      addr ← (addr + 1) mod N; // 주소 = (주소 + 1) % N
      if (addr == home - addr ) { // 한 바퀴 다 돈 경우
         print ("file is completely full"); // 화일이 꽉참
         return;
      }
   }
   insert the key at addr;
   set the addr is full;
end insertLinear()
```

- 오버플로 발생시, 홈 주소에서부터 차례대로 조사해서 가장 가까운 빈 공간을 찾는 방법
- 해당 주소가 공백인지 아닌지 판별을 할 수 있어야 한다. (flag 를 이용해서 판별하자)
- **단점**

  어떤 레코드가 파일에 없다는 것을 판단하기 위해 조사해야하는 주소의 수는 적재율이 커질수록 많아진다.

환치 : 한 레코드가 자기 홈 주소를 동거자가 아닌 레코드가 차지함으로 인해 다른 레코드의 홈 주소에 저장되는 것 -> <u>2-패스 해시 파일 생성</u>으로 대응

- **2-패스 해시 파일**

  첫 번째 패스

  - 모든 레코드를 해시 함수를 통해 홈 주소에 저장한다.
  - 충돌이 일어나는 동거자들은 바로 저장하지 않고 별도로 임시 화일에 저장한다

  두 번째 패스

  - 임시 화일에 저장해 둔 동거자들을 선형 조사를 이용해 화일에 모두 적재한다.

  특징

  - 1-패스 생서에 비해 훨씬 많은 레코드들이 원래 자시 홈 주소에 저장된다
  - 화일 생성 이전에 레코드 키 값들을 미리 알 때 효율적이다.
  - 화일이 생성된 이후에 레코드들이 추가되면 환치가 발생한다.

- 저장

  원형 탐색 : 빈 주소를 조사하는 과정은 홈 주소에서 시작하여 화일 끝에서 끝나는 것이 아니라 다시 화일 시작으로 돌아가 홈 주소에 다다를 때 끝난다.

- 검색

  레코드 저장 시에 선형 조사를 사용했다면, 검색에서도 선형 조사를 사용해야한다.

  버킷에서 빈 공간이 발견되면 검색을 중단한다.

  탐색 키 값을 가진 레코드가 **없거나**, **홈 주소에서 멀 경우**, 많은 조사가 필요하다.

- 삭제

  삭제로 인해 만들어진 빈 공간으로 검색시 선형 조사가 단절될 수 있다 (삭제 표시를 하자)

  다음은 삭제에 대한 예시이다.

- 가정
  - A, B, C, D가 200에 해싱됨
  - W, X, Y가 202에 해싱됨
- 삽입
  - A, B, C, W, D, X, Y 순서로 삽입됨
- 삭제
  - 레코드 W가 삭제되면, 이후 오버플로우 레코드 D, X, Y에 대한 검색은 항상 실패하게 됨
- 해결책
  - 논리적 삭제 표시를 사용

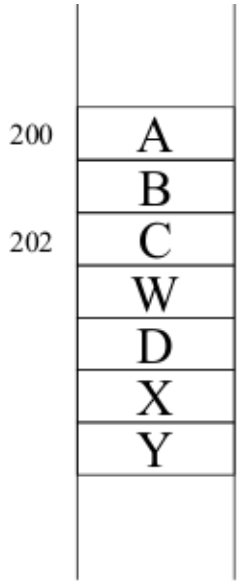

독립 오버플로 구역

- 예시

- 별개의 하나의 오버플로 구역을 할당하여 홈 주소에서 오버플로된 모든 동거자들을 순차로 저장하는 방법
- **장점**

  동거자가 없는 레코드에 대해서는 한번의 홈 주소 접근만으로도 레코드를 검색

  1-패스로 상대 파일을 생성

  환치 문제 제거

- **단점**

  오버플로된 동거자를 접근하기 위해서는 오버플로 구역에 있는 모든 레코드들을 순차적으로 검색해야 한다.

이중 해싱

- 오버플로된 동거자들을 오버플로 구역으로 직접 해시

  오버플로 구역에서의 순차 탐색을 피할 수 있다

  2 차 해시 함수

  - 오버플로된 동거자를 해시하는 함수

- 해싱 과정

  1 차 해시 함수에 의해 상대 파일로 해시

  오버플로가 발생하면, 오버플로 구역으로 해시

  - 오버플로 구역 주소 = (1 차 해시 함수값 + 2 차 해시 함수값) mod (오버플로 구역 크기)

  오버플로 구역에서 또 충돌이 일어난 경우 선형 탐색을 이용한다.

동거자 체인

동거자 체인 + 독립 오버플로 구역 예

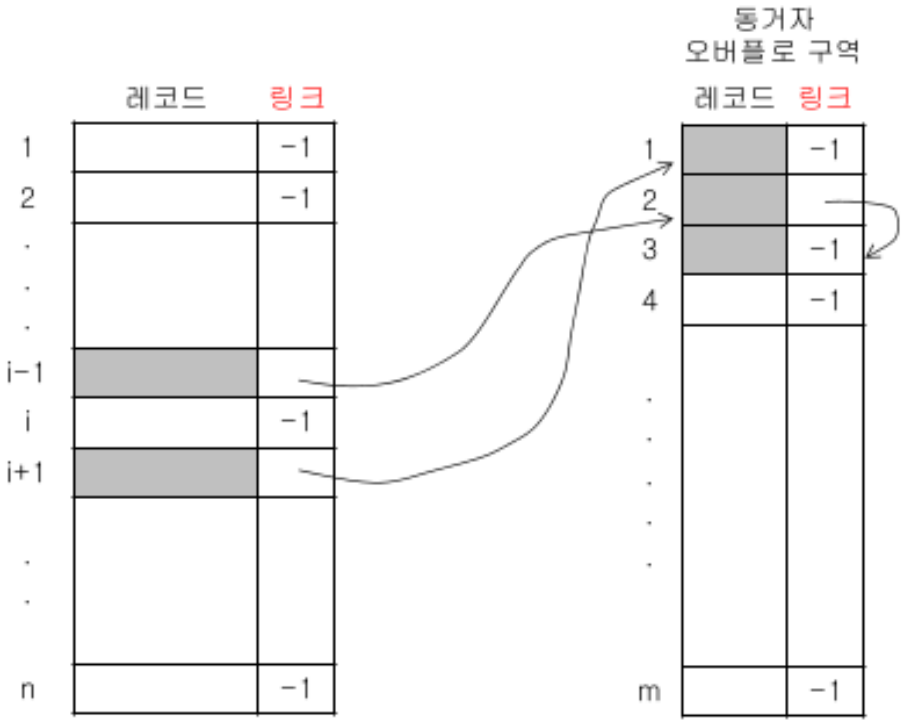

- 각 주소마다 링크를 두어 오버플로된 레코드들을 연결하는 방법

  오버플로가 일어나면 선형 조사나 오버플로 구역을 이용해서 저장 후, 처음 해시 주소에 동거자를 포함하고 있는 주소에 대한 링크를 둔다.

  동거자에 대한 접근은 연결된 동거자들만 조사해 보면 된다.

- 독립 오버플로 구역에 사용할 수도 있고 원래의 상대 파일에 적용할 수도 있다.

- **장점**

홈 주소에서의 충돌 감소

환치 제거 (독립 오버플로 구역 사용시)

- **단점**

  각 주소가 링크 필드를 포함하도록 확장

버킷 주소법

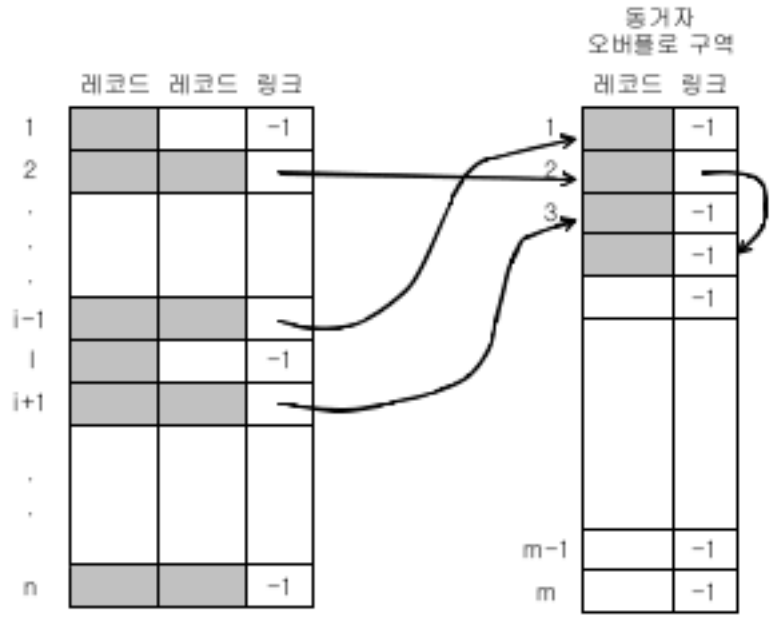

버킷 체인을 사용하는
버킷 주소법의 예

- 해싱 함수가 주어진 키 값으로부터 생성한 주소가 어느 특정 버킷이 되도록 사상하는 것

  하나의 해시 주소에 가능한 최대 수의 동거자를 저장할 수 있는 공간을 할당

  특정 해시 주소에 대한 모든 동거자들은 그 특정 해시 주소의 버킷에 순차로 저장

  한 레코드를 검색하기 위하여 조사해야 될 레코드 수는 최대로 버킷 사이즈에 한정 (오버플로 구역 탐색, 화일 전체 탐색 불필요)

- 문제점

  공간의 낭비 : 각 해시 주소에 대한 동거자의 수가 다양하고 그 차이가 아주 클 때

  - 버킷 사이즈는 해시 주소에 대한 최대 동거자 수로 정하는 것이 보통 → 낭비된 공간 ↑

  버킷 사이즈 설정

  - 화일 생성 전에 데이타를 분석할 수 없을 때, 설 정이 어려움
  - 사이즈가 충분치 않으면 오버플로 발생 → 충돌 해결 기법 필요

- 버킷 주소법에서의 충돌 해결

여유 공간을 가진 가장 가까운 버킷을 사용하는 방법

버킷 체인

- 홈 버킷에서 오버플로가 일어나면 별개의 버킷을 할당받아 오버플로된 동거자를 저장하고 홈 버킷에 이 버킷을 링크로 연결
- **장점** : 재해싱 불필요
- **단점** : 한 레코드를 탐색하기 위해서는 최악의 경우 그 홈 버킷에 연결된 모든 오버플로 버킷을 조사해야 함

- 버킷 주소법의 성능

성공적 탐색 : 어떤 다른 방법보다도 평균 조사 수가 더 작다

실패 탐색 : 성공적 탐색과 비슷하거나 더 작다

오버플로 처리 기법들의 성능 비교 (선형 조사 / 이중 해싱 / 동거자 체인)

1. 성공적 탐색 성능
   - 선형 조사가 월등하게 우수하다.

     (검색시간 : 동거자 체인 > 이중 해싱 > 선형 조사)
2. 실패 탐색 성능
   - 동거자 체인이 월등히 우수하다.

...